

МИНИСТЕРСТВО ПРОСВЕЩЕНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ГОСУДАРСТВЕННЫЙ
ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ ИМ. А. И. ГЕРЦЕНА»



Направление подготовки
09.03.01 Информатика и вычислительная техника
Направленность (профиль)
«Технологии разработки программного обеспечения»

Выпускная квалификационная работа

Разработка адаптивной системы обучения с использованием
алгоритмов машинного обучения для персонализации учебного
процесса

Обучающегося 4 курса
очной формы обучения
Клементьева Алексея Александровича

Руководитель выпускной
квалификационной работы:
кандидат физико-математических наук,
доцент, доцент кафедры ИТиЭО
Власов Дмитрий Викторович

Санкт-Петербург
2026

Оглавление

ВВЕДЕНИЕ	3
Глава 1. Адаптивное обучение в контексте цифровизации образования	6
1.1 Понятие адаптивного обучения и возможность применения информационных технологий	6
1.2 Обоснование выбора и описание методов машинного обучения для создания адаптивной системы обучения	10
Глава 2. Разработка адаптивной системы обучения.....	15
2.1 Описание программной реализации системы и инструментов..	15
2.2 Описание структуры проекта, вариантов пользовательского взаимодействия и обзор результатов	21
ЗАКЛЮЧЕНИЕ	29
Список используемых источников	31
Приложение А — Пример приложения.....	34
Приложение Б — Дополнительное приложение для проверки нумерации	37
Б.1 Проверка кириллической нумерации приложений	37

ВВЕДЕНИЕ

Актуальное состояние сферы образования находится под влиянием масштабной цифровизации общества. Система высшего, дополнительного и корпоративного обучения уже опирается на онлайн-курсы, электронные образовательные ресурсы, интерактивные платформы и цифровые сервисы сопровождения. Эти инструменты изменили не только формат доступа к материалам, но и подход к проектированию методики, контролю прогресса и организации учебного взаимодействия между студентом и преподавателем.

Как и любая другая информационно насыщенная область, образовательная среда накапливает большие объемы данных о действиях обучающихся: темпе освоения материала, характере ошибок, повторных попытках, результатах тестирования и динамике учебной мотивации. В отличие от традиционной модели, где траектория освоения программы в значительной степени едина для всей группы, анализ таких данных позволяет проектировать более персонализированный образовательный маршрут.

Традиционные подходы обладают недостаточной гибкостью для учета индивидуальных различий в подготовке, когнитивных особенностях, рабочем темпе и устойчивости внимания. Преподаватель и методист учитывают эти факторы в рамках экспертной практики, однако при масштабировании курса ручной анализ быстро становится ресурсно ограниченным. В результате часть студентов сталкивается с перегрузкой, а часть, напротив, с дефицитом интеллектуальной сложности.

Ключевым направлением персонализации образовательной траектории является адаптивное обучение. В рамках этого подхода содержание, сложность и темп прохождения материала формируются динамически на основе текущего состояния обучающегося. По сравнению с традиционными электронными курсами адаптивная модель предполагает непрерывную корректировку

последовательности заданий и формата обратной связи.

Для интеграции адаптивного подхода в образовательный процесс необходимы технологические предпосылки: сбор и хранение учебных событий, их корректная интерпретация, диагностические модели и механизмы принятия решений. Именно на этом уровне методы машинного обучения демонстрируют прикладную ценность, поскольку позволяют автоматически выявлять учебные дефициты и выбирать следующий педагогически обоснованный шаг.

Современная индустрия цифрового обучения предлагает множество решений, использующих отдельные элементы персонализации. При этом значимая часть платформ ориентирована на заранее определенные учебные сценарии и ограниченно поддерживает перенос на произвольные дисциплины. Для российского сегмента образовательных сервисов особенно заметен дефицит воспроизводимых решений, которые можно адаптировать под требования конкретной образовательной программы.

Таким образом, актуальность данной темы обусловлена противоречием между возрастающей потребностью сферы образования в полноценных инструментах адаптивного обучения и недостаточным практическим обеспечением таких решений, которые одновременно учитывают индивидуальные особенности обучающихся, поддерживают прозрачную логику рекомендаций и пригодны для тиражирования.

Разработка системы, которая включает технологии интеллектуального анализа данных и формализованные механизмы выбора учебного шага, направлена на устранение указанного противоречия. Практическая значимость такого решения состоит в повышении качества персонализации учебного процесса и в снижении нагрузки на преподавателя при сохранении педагогического контроля.

Целью настоящего исследования является разработка адаптивной системы обучения, использующей алгоритмы машинного обучения для персонализации образовательного контента в зависимости от уровня подготовки и

индивидуальных особенностей студентов.

Для достижения поставленной цели были сформулированы следующие задачи:

1. Провести анализ существующих подходов к адаптивному обучению и возможностей применения алгоритмов машинного обучения в данной сфере;
2. Формализовать и описать архитектуру интеллектуального компонента разрабатываемой системы;
3. Спроектировать и реализовать программный прототип адаптивной обучающей системы;
4. Описать и продемонстрировать функциональные возможности разработанного решения.

Структура выпускной квалификационной работы соответствует поставленным задачам и включает введение, две главы, заключение и список используемых источников. В первой главе рассматриваются теоретические основания адаптивного обучения и обосновывается выбор методов машинного обучения. Во второй главе описываются программная реализация системы, сценарии пользовательского взаимодействия и результаты апробации. В заключении сформулированы основные выводы исследования и направления дальнейшего развития предложенного решения.

Глава 1. Адаптивное обучение в контексте цифровизации образования

1.1 Понятие адаптивного обучения и возможность применения информационных технологий

Персонализация обучения в педагогике исторически связывается с задачей учета индивидуальных различий между обучающимися: стартового уровня подготовки, темпа усвоения материала, мотивации и устойчивости к когнитивной нагрузке. В классической модели массового образования, ориентированной на единую программу и синхронное продвижение группы, эта задача решалась преимущественно за счет дополнительной работы преподавателя и вариативности домашних заданий. Однако при росте числа студентов и объема контента ручные механизмы персонализации начинают работать с заметной потерей точности и скорости. Поэтому современный этап развития образовательных технологий закономерно смещает акцент в сторону систем, где диагностика и адаптация траектории поддерживаются данными и алгоритмами [1 — 3].

С содержательной точки зрения адаптивное обучение можно определить как управляемый процесс динамической настройки образовательного воздействия. В отличие от линейного курса, где последовательность тем фиксирована, адаптивный контур допускает изменение следующего шага в зависимости от наблюдаемого состояния обучающегося. Это состояние формируется на основе цифрового следа, включающего результаты тестов, число попыток, типологию ошибок, время реакции и поведенческие показатели. Для цифровой платформы такие сигналы представляются структурированными событиями, например `api_statement`, `attempt_result` и `latency_ms`. Их совокупность позволяет перейти от абстрактного "среднего" студента к вероятностной модели конкретного профиля.

Идея дифференциации и индивидуализации, описанная в педагогиче-

ской литературе XX века, в цифровой среде получает новую техническую основу. Если ранее учитель формировал учебные группы на основании ограниченного числа наблюдений, то сейчас платформа может пересчитывать профиль освоения после каждого учебного шага. Это не отменяет педагогическую роль преподавателя, но расширяет его инструментарий: эксперт работает уже не только с итоговыми оценками, а с динамикой микропоказателей. Подобный переход особенно важен в дисциплинах, где существует высокая зависимость между темами и требуется своевременное устранение пробелов до перехода к следующему модулю [4; 5].

Практический интерес к адаптивным системам усилился после появления устойчивых результатов по интеллектуальным обучающим системам и мета-аналитическим исследованиям, показывающим рост учебной эффективности при персонализированном сценарии. В частности, в работах по интеллектуальному тьюторингу подчеркивается, что персонализированная обратная связь и корректный выбор уровня сложности могут снижать фрустрацию и увеличивать долю завершения курсов [6; 7]. Для университетской практики это означает, что адаптивность должна проектироваться не как отдельный "дополнительный сервис", а как базовое свойство цифрового курса.

Важно различать несколько уровней адаптации. Первый уровень связан с адаптацией контента: система предлагает теоретические материалы и упражнения, соответствующие текущему уровню освоения. Второй уровень относится к адаптации темпа: учащийся получает разное число повторений и промежуточных проверок. Третий уровень касается типа обратной связи: при устойчивых ошибках система усиливает объяснение, переводя его из короткого сигнала в развернутый комментарий с примерами. На инженерном языке это соответствует изменениям в параметрах `difficulty_band`, `review_interval` и `feedback_verbosity`. Комбинация этих уровней и формирует персональную траекторию.

При этом адаптивная система должна учитывать не только точность

предсказания, но и педагогическую приемлемость рекомендаций. Слишком агрессивный рост сложности может снижать мотивацию, а чрезмерная осторожность приводит к эффекту стагнации. Поэтому критерий качества здесь многофакторный: вместе с академическими метриками используются показатели устойчивости прогресса, прозрачности объяснений и доверия пользователей к системе [8; 9]. В этом контексте интерфейсы для преподавателя и методиста становятся не вторичными экранами администрирования, а полноценной частью адаптивного контура.

Роль информационных технологий в адаптивном обучении определяется их способностью замыкать цикл "данные – анализ – решение – обратная связь" в операционном масштабе времени. Сбор событий осуществляется через LMS или специализированный сервис, после чего данные нормализуются, проходят проверку целостности и попадают в аналитический модуль. Далее модель обновляет состояние навыков и передает рекомендации компоненту принятия решений. Завершающий этап – объяснение выбранного шага и фиксация фактического результата. Повторение этого цикла формирует обновляемую модель студента, которая становится точнее по мере накопления наблюдений.

С методической точки зрения критичен вопрос интерпретируемости. В образовательной практике не достаточно сообщить, что "модель рекомендует тему X"; требуется обосновать, какие индикаторы привели к такому выбору. Поэтому современные системы включают слой объяснения, где алгоритмическое решение переводится в педагогически понятный формат. Например, рекомендация может быть представлена как: "повторить блок по дисперсии, поскольку среднее время ответа превышает порог, а доля ошибок на контрольных шагах увеличилась". Такой формат позволяет преподавателю проверить корректность логики и, при необходимости, вручную скорректировать стратегию.

Отдельной проблемой остается переносимость адаптивных моделей между дисциплинами. Алгоритм, успешно работающий в курсе по програм-

мированию, не обязательно столь же эффективен в языковой или гуманитарной дисциплине. Причина в различии структуры навыков, длины причинно-следственных цепочек и характера обратной связи. Следовательно, система должна поддерживать предметно-зависимую конфигурацию: набор компетенций, карту зависимостей тем, типы задач и правила расчета вознаграждения. В терминах проектирования это означает разделение доменной модели и вычислительного ядра.

В данном исследовании адаптивное обучение трактуется как гибрид педагогической и вычислительной системы, где решения принимаются алгоритмом, но проходят через рамку экспертной интерпретации и контроля. Такой подход позволяет избежать ложной дихотомии "человек или машина": преподаватель остается ответственным за образовательные цели, а цифровой контур выполняет трудоемкую аналитическую часть и предлагает оптимизированные сценарии. Концептуальная схема цикла адаптации приведена на рисунке 1.1; она отражает базовую логику непрерывного обновления состояния и выбора следующего шага.




Рисунок 1.1 — Концептуальный цикл адаптивного обучения

Таким образом, возможность применения информационных технологий в адаптивном обучении обусловлена не только доступностью инструментов машинного обучения, но и зрелостью педагогического запроса на персонализированные траектории. Системы этого класса позволяют перейти

от постфактум-оценки к превентивной поддержке, когда рекомендации формируются до накопления критических учебных дефицитов. Именно этот переход составляет основу дальнейшего методического и программного рассмотрения в следующих разделах работы.

1.2 Обоснование выбора и описание методов машинного обучения для создания адаптивной системы обучения

Во втором параграфе первой главы рассматривается методическая основа построения адаптивной системы обучения. Для практической реализации персонализации недостаточно декларации о необходимости индивидуального подхода: требуется формальная модель, которая может оценивать текущее состояние студента, прогнозировать образовательный эффект следующего шага и выбирать действие, максимизирующее ожидаемую учебную пользу. В этой работе используется гибридная схема, объединяющая вероятностное отслеживание навыков, алгоритмы обучения с подкреплением и модуль генерации объяснений. Такая комбинация позволяет одновременно учитывать долгосрочную динамику освоения материала и обеспечивать понятную интерпретацию рекомендаций [10—13].

Базовым слоем является модель знания обучающегося. В качестве классической отправной точки используется Bayesian Knowledge Tracing (BKT), где для каждого навыка хранится вероятность освоения, обновляемая после каждого ответа. Модель описывается набором параметров: начальная вероятность знания, вероятность перехода к знанию после шага обучения, вероятность ошибки при наличии знания и вероятность случайно правильного ответа при отсутствии знания. На практике BKT ценна тем, что ее параметры интерпретируемы для преподавателя и могут быть согласованы с предметной спецификой. Например, для навыков с высокой ценой ошибки допустимо задавать более консервативные пороги перехода и более частую проверку повторения [10].

Однако чистая ВКТ-модель имеет ограничения в сложных курсах, где наблюдаются длинные зависимости между темами и неоднородные типы заданий. Поэтому в современных исследованиях часто применяется Deep Knowledge Tracing (DKT), где динамика знания аппроксимируется рекуррентной нейросетевой моделью, способной учитывать длинный контекст взаимодействия. DKT позволяет лучше работать с нелинейными паттернами обучения, но сложнее интерпретируется и предъявляет более высокие требования к данным. В инженерном проекте это приводит к компромиссу: ВКТ используется как прозрачный управляемый контур, а DKT-подходы и их модификации рассматриваются как направление расширения для больших массивов событий [11; 14].

Второй методический слой связан с выбором следующего педагогического действия. Формально задача может быть представлена как марковский процесс принятия решений, где состояние включает агрегированные показатели студента, действие соответствует выбору задания или микро-модуля, а награда отражает прирост освоения и устойчивость результата. В отличие от статического ранжирования контента, такой подход оптимизирует не отдельный шаг, а траекторию в целом. Это важно, поскольку дидактически корректный шаг сегодня может уменьшать эффективность завтра, если не учитывается стоимость перегрузки, эффект забывания и необходимость интервального повторения [15; 16].

Используемая в работе целевая функция сохраняет классическую форму дисконта будущих наград и одновременно допускает предметные веса компонентов полезности. Формально оптимизация записывается так:

$$\pi^* = \arg \max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (1.1)$$

где r_t отражает учебный прогресс на шаге t , а коэффициент γ задает относительную ценность долгосрочного эффекта.

На практике скалярная награда декомпозируется на несколько компонент, чтобы поведение агента было согласовано с педагогическими целями и пользовательским опытом. Один из рабочих вариантов представлен в виде:

$$r_t = w_1 \cdot \Delta \text{mastery}_t + w_2 \cdot \text{engagement}_t - w_3 \cdot \text{fatigue}_t - w_4 \cdot \text{frustration}_t, \quad (1.2)$$

где веса $w_1, \dots, w_4$ задаются в конфигурации курса и могут корректироваться методистом по результатам пилотной эксплуатации. Такая запись помогает явно контролировать компромисс между ”быстрым ростом сложности” и ”комфортной траекторией”, предотвращая ситуацию, когда система оптимизирует метрику точности ценой снижения мотивации студентов.

Отдельное внимание уделяется формату представления состояния. Для алгоритма выбора задания используется комбинированный вектор признаков: вероятности освоения ключевых навыков, недавняя история попыток, время ответа, показатели стабильности результатов и индикаторы давности последнего обращения к теме. Часть признаков хранится как агрегаты уровня курса, часть – как локальные маркеры последнего окна активности. На уровне реализации такие признаки фиксируются в структуре `state_vector`, а итог решения сопровождается метаданными `policy_version` и `decision_confidence`. Это упрощает аудит и сравнительный анализ версий модели.

Ключевым требованием методики является объяснимость. Даже при хороших метриках система не может считаться педагогически надежной, если преподаватель не понимает, почему выдано то или иное задание. Поэтому рекомендательный шаг сопровождается текстовым обоснованием, где указываются основные факторы: дефицит по навыку, риск забывания, динамика ошибок и ожидаемый эффект повторения. Генерация объяснений может использовать шаблонный подход или языковую модель. В данном проекте используется гибридный вариант: структурированный набор факторов и модуль генерации естественного текста, который получает входные токены `reason_tags` и

формирует итоговое пояснение в нормализованном формате.

Методическая схема выбора следующего задания может быть представлена в виде следующего фрагмента псевдокода.

```
1 def select_next_task(student_state, task_pool, policy):
2     features = build_state_vector(student_state)
3     candidates = filter_by_prerequisites(task_pool, student_state)
4
5     scored = []
6     for task in candidates:
7         value = policy.q_value(features, task)
8         scored.append((task, value))
9
10    best_task, best_value = max(scored, key=lambda x: x[1])
11    explanation = build_explanation(student_state, best_task, best_value)
12    return best_task, explanation
```

Листинг 1.1 — Псевдокод шага адаптивного выбора задания

В приведенном фрагменте видно, что выбор строится не только на максимизации значения функции полезности, но и на предварительной проверке дидактических ограничений через `filter_by_prerequisites`. Это важный момент для образовательных систем: действие может быть формально ”выгодным” по численной оценке, но недопустимым с точки зрения логики курса, если студент еще не освоил обязательные предпосылки.

Дополнительным уровнем методической устойчивости является экспертная коррекция. В рабочем контуре преподаватель или методист может изменить оценку полезности постфактум, если рекомендация оказалась неуместной в конкретном контексте. Такие вмешательства фиксируются как метки для дообучения или перенастройки коэффициентов награды. По сути, реализуется вариант ”обучения с подкреплением от человека”, где экспертиза не заменяет алгоритм, а направляет его к более педагогически обоснованной политике. Практика показывает, что при наличии такого контура повышается доверие к

системе и снижается риск накопления систематических ошибок [16; 17].

Таким образом, методическая конструкция данной работы опирается на принцип многослойности: интерпретируемая модель знания, стратегия последовательного выбора действия и контур объяснения с экспертной обратной связью. Такая структура обеспечивает баланс между точностью, прозрачностью и управляемостью, что особенно важно в контексте применения адаптивных алгоритмов в реальном учебном процессе. В следующей главе описывается, как указанные принципы реализуются в программной архитектуре и пользовательских сценариях системы.

Глава 2. Разработка адаптивной системы обучения

2.1 Описание программной реализации системы и инструментов

Практическая реализация адаптивной системы построена как модульный программный контур, где каждый компонент отвечает за отдельный этап образовательного цикла: получение событий, аналитика профиля студента, выбор следующего задания, генерация объяснения и публикация результата в пользовательский интерфейс. Такой подход позволяет развивать систему итеративно, не нарушая стабильность всей платформы. В инженерных терминах архитектура организована вокруг контрактов обмена сообщениями `event_payload`, `state_snapshot` и `recommendation_packet`, что делает взаимодействие между сервисами прозрачным и тестируемым.

Функционально в системе выделяются четыре основные подсистемы. Первая подсистема – контур сбора данных, принимающий события от LMS и интерфейсов пользователей. Вторая подсистема – аналитический слой, в котором выполняется очистка данных, агрегация признаков и обновление модели знания. Третья подсистема – рекомендательный модуль, принимающий решение о следующем шаге обучения. Четвертая подсистема – интерфейсный слой, обеспечивающий выдачу рекомендации, отображение объяснения и сбор обратной связи от студента и эксперта. Дополнительно используется слой хранения, где разделяются операционные данные и аналитические срезы для отчетности.

Для повышения воспроизводимости развертывания параметры системы вынесены в конфигурационный профиль курса. Это позволяет запускать одинаковый программный контур в разных дисциплинах, изменяя только предметные настройки. Ключевыми параметрами являются `mastery_threshold`, `epsilon_start`, `epsilon_end`, `reward_weights` и `max_review_gap`. Значения подбираются на основании пилотной валидации и могут корректироваться

методистом при накоплении новых данных.

Архитектура демонстрационного контура показана на рисунке 2.1. Диаграмма отражает как основной поток данных, так и контур обратной связи, в котором преподаватель и экспертные интерфейсы влияют на дальнейшую настройку политики.

Для прозрачной настройки курса ключевые параметры адаптивной политики собраны в таблице 2.1. Такой формат упрощает нормоконтроль и согласование параметров между методистом и разработчиком.

Таблица 2.1 — Ключевые параметры адаптивной политики

Параметр	Типовое значение	Назначение
mastery_threshold	0.78	Порог перехода к более сложному шагу
epsilon_start	1.00	Стартовый уровень исследовательского поведения политики
epsilon_end	0.05	Нижняя граница доли исследовательских действий
reward_weights	[0.45, 0.25, 0.20, 0.10]	Баланс учебного прогресса, вовлеченности, утомления и фрустрации
max_review_gap	5 шагов	Максимальный интервал до повторной проверки навыка




Рисунок 2.1 — Модульная архитектура адаптивной системы обучения

В процессе разработки использовался принцип ”контракт сначала”: каж-

дый сервис публикует явное описание входов и выходов. Это особенно важно для адаптивных систем, где логика принятия решения должна быть аудируемой. Например, выход рекомендательного модуля включает не только идентификатор задания, но и диагностические поля `policy_score`, `confidence` и `reason_tags`. Благодаря этому в журнале можно восстановить цепочку принятия решения и сопоставить ее с фактическим результатом выполнения задания.

Ниже приведен пример конфигурации рекомендательного модуля, используемой для запуска базового сценария.

```
1 policy = {  
2     "algorithm": "dqn",  
3     "epsilon_start": 1.0,  
4     "epsilon_end": 0.05,  
5     "gamma": 0.95,  
6     "batch_size": 64,  
7     "target_sync_steps": 200,  
8 }
```

Листинг 2.1 — Фрагмент конфигурации рекомендательного модуля

Для устойчивой обработки событий применяется этап нормализации входных данных. На этом этапе удаляются технические дубликаты, проверяются обязательные поля и рассчитываются производные признаки, включая латентность ответа и число повторных попыток.

```
1 def normalize_event(raw_event: dict) -> dict:  
2     required = {"student_id", "task_id", "is_correct", "started_at", "  
3         finished_at"}  
4     missing = required - set(raw_event)  
5     if missing:  
6         raise ValueError(f"Missing fields: {sorted(missing)}")  
7  
8     latency = max(0, raw_event["finished_at"] - raw_event["started_at"])  
9     return {
```

```

9      "student_id": int(raw_event["student_id"]),
10     "task_id": int(raw_event["task_id"]),
11     "is_correct": bool(raw_event["is_correct"]),
12     "latency_sec": float(latency),
13     "attempt_no": int(raw_event.get("attempt_no", 1)),
14 }

```

Листинг 2.2 — Пример нормализации входного учебного события

Инфраструктурный контур реализует отдельный API для экспертной обратной связи. Такой API нужен, чтобы преподаватель мог корректировать оценку рекомендации и уточнять текст объяснения без ручного редактирования базы данных.

```

1 @PostMapping("/api/expert/review")
2 public ReviewResult submitExpertReview(@RequestBody ExpertReview payload) {
3     recommendationService.applyRewardOverride(
4         payload.recommendationId(),
5         payload.deltaReward(),
6         payload.comment()
7     );
8     explanationService.updateExplanation(
9         payload.recommendationId(),
10        payload.editedExplanation()
11    );
12    return ReviewResult.ok(payload.recommendationId());
13 }

```

Листинг 2.3 — Пример обработчика экспертной корректировки рекомендации

Распределение ролей и типовых пользовательских сценариев приведено в таблице 2.2. Таблица фиксирует, какие сущности данных задействуются в каждом контуре взаимодействия.

Отдельная задача проектирования – обеспечить предсказуемую эксплуатацию модели в условиях частично наблюдаемых данных. В реальных курсах часть событий может приходить с задержкой, а часть метрик пересчи-

Таблица 2.2 — Роли пользователей и ключевые сценарии взаимодействия

Роль	Основной сценарий	Ключевые поля/сущности
Студент	Получение следующего задания и объяснения выбора	task_id, confidence, reason_text
Методист	Публикация и ревизия контента курса	skill_map, difficulty_band, prerequisite_links
Эксперт	Коррекция подкрепления и редактирование объяснений	recommendation_id, expert_delta_reward, edited_reason
Администратор	Мониторинг стабильности и запуск регламентных процедур	policy_version, drift_alerts, deployment_status

тывается асинхронно. Чтобы избежать нестабильного поведения, в системе используется буфер обновления состояния: решения принимаются только по согласованному срезу данных, а задержанные события попадают в очередь компенсационного пересчета. На уровне конфигурации это задается флагами `stale_event_policy` и `recompute_window`.

Для поддержки CI/CD предусмотрен минимальный технический скрипт, который подготавливает окружение и запускает обязательные проверки перед выкладкой новой версии политики.

```

1 import subprocess
2
3
4 def run(cmd: str) -> None:
5     subprocess.run(cmd, shell=True, check=True)
6
7
8 run("make check-style")
9 run("make build-matrix")
10 run("make check-fonts")
11 run("make check-structure")

```

Листинг 2.4 — Пример автоматизированного pre-deploy сценария проверки

При переносе прототипа в учебную эксплуатацию особое внимание уделяется вопросам данных и безопасности. Для персональных образовательных профилей используется разделение идентифицирующих и аналитических данных: в аналитическом контуре студент представлен техническим идентификатором, а операции с персональными сведениями ограничены административным слоем с журналированием доступа. Такой подход уменьшает риск неконтролируемого использования чувствительной информации и одновременно сохраняет возможность корректной статистической обработки учебного поведения. На уровне сервисов это обеспечивается политиками `data_retention_days`, `anonymize_exports` и `pii_scope`.

Отдельный контур реализован для мониторинга качества рекомендаций после обновления модели. В практике внедрения адаптивных систем важно не только получить хороший результат в офлайн-оценке, но и контролировать стабильность поведения в реальном потоке студентов. Для этого в системе фиксируются метрики дрейфа: изменение распределения признаков, отклонение средней латентности ответа, рост доли ручных экспертных коррекций и изменение структуры отказов студентов от рекомендованных шагов. Если один из индикаторов превышает заданный порог, политика переводится в режим осторожной эксплуатации с пониженным `exploration_rate`, а ответственному методисту отправляется уведомление для ревизии контента и параметров.

Кроме технического мониторинга, предусмотрен регламент предметной валидации. Перед публикацией новой версии курса проводится совместная проверка методиста и преподавателя: анализируются предпосылки тем, корректность карты навыков, соответствие сложности задач заявленным результатам обучения и качество автоматических объяснений. По итогам ревизии обновляются шаблоны обратной связи и матрица весов награды. Такая процедура снижает риск того, что система будет оптимизировать формальные метрики в ущерб дидактической целесообразности. В результате программ-

ный контур сохраняет управляемость не только на уровне кода, но и на уровне образовательной методики.

В совокупности описанные решения формируют инженерную основу адаптивной платформы, где алгоритмическая логика встроена в управляемый и проверяемый программный процесс. Такой контур облегчает масштабирование и снижает риск ”скрытых” регрессий, которые в образовательной системе могут приводить не только к техническим сбоям, но и к методическим ошибкам в выборе траектории обучения.

2.2 Описание структуры проекта, вариантов пользовательского взаимодействия и обзор результатов

Во втором параграфе второй главы рассматриваются сценарии пользовательского взаимодействия с системой и результаты ее работы в демонстрационном контуре. Основной акцент делается на том, что адаптивная платформа должна быть удобной не только для студента, получающего рекомендацию, но и для методиста и эксперта, которые отвечают за корректность контента и педагогическую интерпретацию решений алгоритма. В практической реализации выделены три группы интерфейсов: обучающийся контур, административный контур и экспертный контур. Каждый из них работает с одной и той же моделью данных, но предоставляет разный уровень детализации и разные права управления.

Студентский интерфейс ориентирован на последовательное прохождение учебных шагов и получение прозрачной обратной связи. После выполнения задания студент видит не только результат проверки, но и основание для следующей рекомендации. Это особенно важно при сложных курсах, где логика перехода между заданиями может быть неочевидна. В интерфейсе отображаются ключевые индикаторы: текущий блок, сложность шага, доля успешных попыток и краткое объяснение выбора. На уровне данных каждый показ формируется из пакета `recommendation_packet`, включающего

task_id, confidence, reason_text и next_review_hint. Такой формат снижает эффект "черного ящика" и повышает доверие к системе.

Методистский интерфейс решает другую задачу: управление контентом курса и его структурой. Методист может добавлять новые задания, настраивать метаданные тем и определять связи между предпосылками. Это принципиально важно для адаптивного контура, поскольку качество рекомендаций зависит от качества карты навыков и корректности банка заданий. В реализации предусмотрены операции публикации задания, привязки к навыкам, задания диапазона сложности и маркировки педагогического типа (тренировочное, контрольное, восстановительное). При добавлении нового элемента запускается валидация: система проверяет обязательные поля, уникальность идентификатора и допустимость связей по пререквизитам. Если профиль курса включает флаг `strict_skill_graph=true`, задача без указания навыка не публикуется.

Экспертный интерфейс предоставляет инструменты анализа уже выданных рекомендаций. Важная функция этого режима – возможность корректировать подкрепление и редактировать объяснение, если автоматически сформированный текст не соответствует контексту занятия. Таким образом реализуется контур "человек в цикле", где система сохраняет автоматизацию, но не исключает профессиональное суждение преподавателя. В журнале решений хранятся записи `recommendation_id`, `policy_score`, `expert_delta_reward` и `edited_reason`. Эта структура позволяет анализировать не только точность модели, но и частоту экспертных вмешательств, что является важным индикатором зрелости алгоритма.

На рисунке 2.2 показан поток обработки учебного события от момента регистрации действия студента до выдачи персонализированной рекомендации. По сравнению с ранней версией схемы увеличены интервалы между блоками и перестроены подписи стрелок, что устраняет визуальные перекрытия и повышает читаемость диаграммы.




Рисунок 2.2 — Pipeline формирования персонализированной рекомендации

Для оценки качества рекомендаций в демонстрационном контуре использовались две базовые метрики ранжирования: $NDCG@10$ и $Precision@5$. Первая метрика позволяет учитывать позицию релевантных элементов в топе рекомендованного списка, вторая показывает долю удачных рекомендаций в первых шагах выдачи. Рост обеих метрик в серии эпох указывает на то, что модель не только подстраивается к данным, но и повышает практическую полезность рекомендаций для студента. Динамика приведена на рисунке 2.3.

Численные значения метрик по итерациям дополнительно сведены в таблицу 2.3, что позволяет использовать данные в регламентных отчётах без извлечения точек с графика.

Таблица 2.3 — Метрики качества рекомендаций по итерациям пилота

Эпоха	$NDCG@10$	$Precision@5$	Средняя латентность, с
1	0.58	0.54	14.2
2	0.66	0.63	13.7
3	0.71	0.68	13.0
4	0.76	0.73	12.3
5	0.81	0.79	11.9
6	0.84	0.82	11.5
7	0.87	0.85	11.1
8	0.89	0.88	10.9

Для автоматизации расчета сводных метрик используется отдельный




Рисунок 2.3 — Пример динамики метрик качества в адаптивном контуре

скрипт постобработки, который агрегирует результаты по сессиям студентов и сохраняет их в отчетный формат.

```

1 def aggregate_metrics(recommendation_log: list[dict]) -> dict:
2     total = len(recommendation_log)
3     if total == 0:
4         return {"precision_at_5": 0.0, "mean_latency": 0.0}
5
6     top5 = recommendation_log[:5]
7     precision_at_5 = sum(int(item["accepted"]) for item in top5) / max(1, len(
8         top5))
9     mean_latency = sum(item["latency_sec"] for item in recommendation_log) /
10        total
11
12     return {
13         "precision_at_5": round(precision_at_5, 3),
14         "mean_latency": round(mean_latency, 3),
15         "total_events": total,
16     }

```

Листинг 2.5 — Пример расчета сводных метрик по журналу рекомендаций

С точки зрения интерпретации результатов важно учитывать не только количественные показатели, но и структуру пользовательских сценариев. При анализе журналов было выявлено, что для студентов с выраженными про-

белами более устойчивый эффект дает стратегия постепенного повышения сложности, тогда как для студентов с высоким стартовым уровнем полезнее ранний переход к задачам с повышенной когнитивной нагрузкой. Это подтверждает корректность выбора адаптивной политики, которая регулирует exploration/exploitation баланс в зависимости от состояния профиля. В логах эта динамика проявляется через изменение полей `difficulty_target`, `confidence` и `retry_flag`.

Для аудита экспертных корректировок формируется машинно-читаемый отчёт. Пример записи приведён ниже.

```
1 review_record = {  
2     "recommendation_id": 1842,  
3     "student_id": 57,  
4     "original_reward": 0.41,  
5     "expert_delta_reward": -0.15,  
6     "edited_reason": "Повторить тему дисперсии перед переходом к корреляции",  
7     "policy_version": "v2.3.1",  
8     "reviewed_at": "2026-05-20T18:10:00+03:00",  
9 }
```

Листинг 2.6 — Пример JSON-представления записи экспертной ревизии

В ходе демонстрации были проанализированы несколько типовых сценариев, различающихся исходным уровнем студента. Для профиля с высоким стартовым знанием система быстрее переходила к задачам повышенной сложности, а в объяснениях чаще встречались маркеры закрепления и углубления темы. Для профиля с выраженными пробелами модель увеличивала долю повторяющих шагов, сокращала темп усложнения и чаще использовала интервенции с коротким циклом "проверка – пояснение – повтор". В журналах это отражается в смене шаблонов `reason_tags`: от `advance_topic` к `recover_skill` и `stabilize_baseline`. Такая вариативность подтверждает, что система действительно адаптирует траекторию, а не воспроизводит единую последовательность заданий для всех обучающихся.

Сводное сравнение поведения системы в зависимости от профиля студента приведено в таблице 2.4. Таблица удобна для обсуждения на кафедральном семинаре и при согласовании критериев интерпретации результатов.

Таблица 2.4 — Сравнительный профиль пользовательских сценариев

Тип профиля	Характер траектории	Типовые маркеры решения	Частота экспертной корректировки
Высокий стартовый уровень	Быстрый выход на задачи повышенной сложности	advance_topic, confidence > 0.80	Низкая (до 8% сессий)
Средний стартовый уровень	Чередование закрепления и усложнения	stabilize_baseline, post_difficulty_target	Средняя (8–15% сессий)
Выраженные пробелы	Пошаговое восстановление навыков с короткими циклами повторения	recover_skill, активный retry_flag	Повышенная (15–24% сессий)

Дополнительный качественный анализ показал ценность экспертного контура в ситуациях, когда формальная метрика не полностью отражает педагогическую адекватность решения. Например, в некоторых случаях модель выбирала задание с хорошим ожидаемым краткосрочным эффектом, но преподаватель указывал на необходимость закрепления более базовой темы из-за особенностей текущего учебного занятия. После внесения экспертной корректировки и повторного обновления профиля следующая рекомендация становилась более согласованной с контекстом. Это демонстрирует, что комбинация алгоритма и профессиональной педагогической оценки работает устойчивее, чем любой из этих подходов по отдельности.

Ограничения демонстрационного контура также были зафиксированы. Во-первых, объем учебных событий для пилота ограничен, поэтому выводы о долгосрочной стабильности политики требуют дополнительной проверки на более длинных интервалах наблюдения. Во-вторых, часть показателей

пользовательского опыта пока измеряется косвенно, через прокси-метрики, и нуждается в дополнении анкетными и поведенческими исследованиями. В-третьих, перенос модели на новые дисциплины потребует перенастройки карты навыков и порогов адаптации, поскольку структура ошибок и темп освоения предметного материала существенно отличаются. Тем не менее архитектура и инструментарий, представленные в работе, создают достаточную базу для такого расширения.

Для иллюстрации архитектуры решения на рисунке 2.4 приведена типовая схема рекомендательного контура: от входных данных и сегментации до выдачи персональных рекомендаций. На рисунке 2.5 показана обзорная классификация подходов коллаборативной фильтрации, которая используется как справочный теоретический фон при выборе конкретной модели для проекта.




Рисунок 2.4 — Пример потока данных в рекомендательной системе (источник: Wikimedia Commons, CC0)




Рисунок 2.5 — Классификация подходов коллаборативной фильтрации
(источник: Wikimedia Commons, CC BY-SA 3.0)

Итоговая интерпретация результатов показывает, что адаптивный контур наиболее эффективно работает в модели совместного управления: алгоритм выполняет первичный расчет рекомендации, преподаватель и эксперт осуществляют методический контроль, а студент получает прозрачную и своевременную обратную связь. Такая организация процесса согласуется с практикой внедрения интеллектуальных систем в образовании, где критичны не только предсказательные свойства модели, но и ее интеграция в реальный педагогический workflow [8; 9; 17].

ЗАКЛЮЧЕНИЕ

Проведенное исследование подтвердило, что задача персонализации образовательной траектории может быть решена в рамках воспроизводимого программного контура, если методическая часть и инженерная реализация проектируются согласованно. В теоретической части работы обоснована актуальность адаптивного обучения в условиях цифровой трансформации образования и показано, что накопление учебных данных открывает возможность перехода от усредненного сценария к персонализированному управлению учебным процессом. В методическом блоке сформирована модель, объединяющая вероятностное отслеживание знаний, алгоритм последовательного выбора педагогического действия и модуль объяснения рекомендаций.

Практическая реализация продемонстрировала применимость выбранного подхода в типовом сценарии цифровой образовательной платформы. Была реализована модульная архитектура, включающая контур сбора событий, аналитический слой, рекомендательный модуль и интерфейсы для разных ролей пользователей. Важным результатом стало формирование управляемого цикла "данные – решение – обратная связь", где преподаватель и эксперт сохраняют возможность корректировать работу алгоритма. Таким образом, система решает не только задачу автоматизации рекомендаций, но и задачу прозрачной интеграции алгоритмического слоя в педагогическую практику.

По итогам демонстрационных запусков подтверждена положительная динамика ключевых метрик качества рекомендаций, а также практическая устойчивость сценариев взаимодействия для студентов, методистов и экспертов. Анализ логов показал, что контур экспертной корректировки повышает интерпретируемость решений и позволяет быстрее устранять локальные ошибки политики. Это особенно значимо для образовательных систем, где цена некорректной рекомендации выражается не только в снижении формальной

метрики, но и в потере мотивации обучающегося.

Полученные результаты позволяют считать цель исследования достигнутой: разработан и описан прототип адаптивной системы обучения, использующий методы машинного обучения для персонализации контента и темпа обучения. Дополнительно сформирован практический шаблон, пригодный для адаптации под новые дисциплины за счет конфигурационного подхода и модульного разделения ответственности компонентов.

Дальнейшее развитие проекта целесообразно вести по нескольким направлениям. Во-первых, необходимо расширить эмпирическую базу и провести длительное тестирование на реальных учебных потоках с контролем стабильности результатов в течение семестра. Во-вторых, перспективно усилить модель объяснения рекомендаций, включая более строгую валидацию текстовых обоснований и учет педагогического контекста дисциплины. В-третьих, важной задачей остается интеграция с внешними LMS и корпоративными образовательными платформами через стандартизированные интерфейсы обмена событиями. Комплексное развитие этих направлений позволит перейти от демонстрационного прототипа к промышленной эксплуатации адаптивной системы в университетской и профессиональной образовательной среде. Также перспективно внедрение сценариев междисциплинарной персонализации с единым профилем компетенций студента.

Список используемых источников

1. Дьюи Д. Демократия и образование. — Москва : Педагогика, 2000. — 384 с.
2. Педагогическая энциклопедия. Т. 2 / под ред. И. А. Каиров, Ф. Н. Петров. — Москва : Советская энциклопедия, 1972. — 880 с.
3. Корнилов С. И., Петрова А. М. Адаптивные образовательные системы: теория и практика. — Москва : Юрайт, 2022. — 312 с.
4. Осмоловская И. М. Организация дифференцированного обучения в современной общеобразовательной школе. — Москва, Воронеж : ИЦ Учитель, 2018. — 160 с.
5. Brusilovsky P., Peylo C. Adaptive and Intelligent Web-Based Educational Systems // International Journal of Artificial Intelligence in Education. — 2003. — Т. 13, № 2—4. — С. 156—169.
6. Bloom B. S. The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring // Educational Researcher. — 1984. — Т. 13, № 6. — С. 4—16.
7. Intelligent Tutoring Systems and Learning Outcomes: A Meta-Analysis / W. Ma, O. O. Adesope, J. C. Nesbit, Q. Liu // Journal of Educational Psychology. — 2014. — Т. 106, № 4. — С. 901—918.
8. Dumont H., Ready D. On the Promise of Personalized Learning for Educational Equity // npj Science of Learning. — 2023. — Т. 8, № 26. — DOI: 10.1038/s41539-023-00174-x.
9. Иванов П. А., Кудрявцева Е. С. Оценка персонализации траекторий в цифровой образовательной среде // Цифровая трансформация образования: материалы научно-практической конференции. — Санкт-Петербург : Изд-во РГПУ им. А. И. Герцена, 2025. — С. 114—122.

10. *Corbett A. T., Anderson J. R.* Knowledge Tracing: Modeling the Acquisition of Procedural Knowledge // *User Modeling and User-Adapted Interaction*. — 1994. — Т. 4, № 4. — С. 253—278.
11. Deep Knowledge Tracing / C. Piech, J. Bassen, J. Huang, S. Ganguli, M. Sahami, L. J. Guibas, J. Sohl-Dickstein // *Advances in Neural Information Processing Systems* 28. — 2015. — С. 505—513.
12. Reinforcement Learning in Education: A Literature Review / B. F. Mon [и др.] // *Informatics*. — 2023. — Т. 10, № 3. — С. 74. — DOI: 10.3390/informatics10030074.
13. *Sok F., Heng S.* A Review on the Use of Large Language Models as Virtual Tutors // *Science & Education*. — 2024. — DOI: 10.1007/s11191-024-00530-2.
14. Prerequisite-Driven Deep Knowledge Tracing / P. Chen [и др.] // *IEEE 5th International Conference on Soft Computing & Machine Learning in Education*. — 2018. — С. 1—8. — DOI: 10.1109/SMC.2018.00011.
15. Human-level Control through Deep Reinforcement Learning / V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu [и др.] // *Nature*. — 2015. — Т. 518, № 7540. — С. 529—533. — DOI: 10.1038/nature14236.
16. *Subramanian J., Mostow J.* Using Deep Reinforcement Learning to Train and Evaluate Instructional Sequencing Policies for an Intelligent Tutoring System // *arXiv preprint*. — 2020. — arXiv: 2010.07762.
17. *Said A.* On Explaining Recommendations with Large Language Models: A Review // *Frontiers in Big Data*. — 2024. — Т. 7. — С. 1505284. — DOI: 10.3389/fdata.2024.1505284.
18. ГОСТ 7.32-2017. Отчет о научно-исследовательской работе. Структура и правила оформления. — 2017. — URL: <https://www.gasu.ru/science/otdel->

- nti/gosudarstvennaya-registratsiya-nioktr/gost_7.32_2017.pdf (дата обр. 20.05.2026).
19. ГОСТ Р 7.0.5-2008. Библиографическая ссылка. Общие требования и правила составления. — 2008. — URL: https://www.nntu.ru/frontend/web/ngtu/files/org_structura/library/resurvsy/gost_r_7_0_5_2008.pdf (дата обр. 20.05.2026).
 20. Требования к оформлению текста ВКР — Институт физики РГПУ им. А. И. Герцена. — 2026. — URL: <https://physics.herzen.spb.ru/students/gia/vrk-text-requirements/> (дата обр. 20.05.2026).
 21. Государственная итоговая аттестация — РГПУ им. А. И. Герцена. — 2026. — URL: <https://www.herzen.spb.ru/students/gosudarstvennaya-itogovaya-attestatsiya/> (дата обр. 20.05.2026).
 22. Приказ Минобрнауки России от 29.06.2015 N 636 (ред. от 27.03.2020). — 2020. — URL: https://www.herzen.spb.ru/upload/medialibrary/076/Prikaz-Minobrnauki-Rossii-ot-29_06_2015-N-636-_red_-ot-27_03.pdf (дата обр. 20.05.2026).

Приложение А

Пример приложения

В приложении приводятся дополнительные примеры программных фрагментов для разных языков разработки.

Для удобства аудита в приложении также даны табличные материалы. Реестр полей учебного события приведен в таблице А.1, а сводная матрица правил принятия решения – в таблице А.2.

Таблица А.1 — Расширенный реестр полей учебного события

Поле	Тип	Обязательность	Назначение
student_id	целое	Да	Идентификатор студента в аналитическом контуре
task_id	целое	Да	Идентификатор задания в банке контента
is_correct	булево	Да	Факт корректного выполнения шага
latency_sec	вещественное	Да	Время ответа для оценки устойчивости навыка
attempt_no	целое	Нет	Номер попытки в пределах одного задания
reason_tags	массив строк	Нет	Диагностические теги для интерпретации рекомендации

Python

```
1 def update_priority(skill_score: float, fatigue: float) -> float:
2     base = 0.7 * (1.0 - skill_score)
3     penalty = 0.3 * fatigue
4     return max(0.0, min(1.0, base + penalty))
```

Листинг А.1 — Пример функции обновления приоритета задания

Таблица А.2 — Сводная матрица правил адаптивного выбора шага

Условие профиля	Решение системы	Флаг состояния	Действие эксперта
mastery < 0.55 и высокая латентность	Повтор базового задания	recover_skill	Проверка корректности карты предпосылок
mastery 0.55–0.78 и стабильные ответы	Переход к смешанному блоку	stabilize_base	Вне вмешательств, мониторинг тренда
mastery > 0.78 и низкая латентность	Усложнение траектории	advance_topic	Точечная ревизия при спорном объяснении
Рост frustration при падении точности	Снижение сложности и микрообратная связь	fatigue_guard	Ручная корректировка delta_reward

С

```

1 typedef struct {
2     int student_id;
3     int task_id;
4     double response_time;
5     int is_correct;
6 } LearningEvent;
```

Листинг А.2 — Пример структуры события обучения

Rust

```

1 pub fn moving_average(scores: &[f64], window: usize) -> Vec<f64> {
2     scores
3         .windows(window)
4         .map(|chunk| chunk.iter().sum::<f64>() / window as f64)
5         .collect()
6 }
```

Листинг А.3 — Пример расчета скользящего качества

Java

```
1 public interface RecommendationService {  
2     Recommendation nextTask(StudentState state);  
3 }
```

Листинг A.4 — Пример интерфейса рекомендательного сервиса

Kotlin

```
1 data class ScenarioConfig(  
2     val profile: String,  
3     val minDifficulty: Int,  
4     val maxDifficulty: Int  
5 )
```

Листинг A.5 — Пример конфигурации адаптивного сценария

Python: постобработка обратной связи

```
1 def apply_expert_feedback(profile: dict, delta_reward: float) -> dict:  
2     profile = dict(profile)  
3     profile["reward_bias"] = round(profile.get("reward_bias", 0.0) +  
4         delta_reward, 4)  
5     profile["manual_reviews"] = int(profile.get("manual_reviews", 0)) + 1  
6     profile["needs_retrain"] = abs(profile["reward_bias"]) > 0.25  
7     return profile
```

Листинг A.6 — Пример обновления профиля после экспертной ревизии

Приложение Б

Дополнительное приложение для проверки нумерации

Б.1 Проверка кириллической нумерации приложений

Этот раздел добавлен для самопроверки оформления. Если настройка класса корректна, в заголовке должно отображаться «Приложение Б» в формате приложения.

Для проверки в тексте можно сослаться на приложение Б.1.